Relatório Técnico AT2: Modelagem e Experimentação para Classificação de Posturas Humanas

Manuel Lucala Zengo

25 de maio de 2025

Sumário

1 Introdução **3**

2 Metodologia **3**
2.1 Preparação do Ambiente e Dados 3
2.2 Modelo A: MediaPipe + Classificador RandomForest 3
2.2.1 Descrição da Abordagem 3
2.2.2 Parâmetros de Configuração e Treinamento 3
2.2.3 Resultados e Métricas 4
2.3 Modelo B: YOLOv8-cls (Classificação) 4
2.3.1 Descrição da Abordagem 4
2.3.2 Parâmetros de Configuração e Treinamento 5
2.3.3 Resultados e Métricas 5

3 Análise Comparativa dos Modelos **7**

4 Seleção do Modelo para AT3 **7**

5 Conclusão da AT2 **8**

1 Introdução

Esta seção do projeto (AT2) teve como objetivo principal o desenvolvimento, treinamento e avaliação comparativa de, no mínimo, dois modelos distintos de aprendizado de máquina para a tarefa de classificação de posturas humanas. As posturas de interesse, definidas e preparadas na AT1, foram 'em pé', 'sentado' e 'em movimento'. O dataset utilizado foi um subconjunto curado do MPII Human Pose Dataset. O propósito final desta etapa é selecionar o modelo mais adequado para integração em um sistema de monitoramento de posturas via API, a ser desenvolvido na AT3.

2 Metodologia

2.1 Preparação do Ambiente e Dados

O dataset para esta atividade foi derivado do MPII Human Pose Dataset, conforme detalhado no relatório da AT1. Após um processo de classificação automática baseado na geometria dos pontos articulares, foram selecionadas amostras para as classes 'em pé', 'sentado' e 'em movimento'. Foram utilizadas 395 imagens no total para a AT2.

As 395 imagens foram divididas em conjuntos de treino e teste/validação na proporção de aproximadamente 75% para treino e 25% para teste/validação, resultando em 296 amostras para treino e 99 para teste/validação. Esta divisão foi aplicada consistentemente para ambos os modelos avaliados, utilizando `random_state=42` para reprodutibilidade. As principais bibliotecas utilizadas incluíram Python, Scikit-learn, MediaPipe, OpenCV, e Ultralytics/PyTorch.

2.2 Modelo A: MediaPipe + Classificador RandomForest

2.2.1 Descrição da Abordagem

O Modelo A adota uma abordagem baseada na extração de características explícitas da pose humana. Primeiramente, para cada imagem, são detectados os pontos articulares (keypoints) utilizando a solução MediaPipe Pose. Esta solução identifica 33 landmarks tridimensionais do corpo humano, fornecendo para cada um as coordenadas (x, y, z) e um score de visibilidade, resultando em um vetor de $33 \times 4 = 132$ características por pessoa detectada na imagem. Esses vetores de características foram então utilizados como entrada para treinar um classificador RandomForest, configurado para distinguir entre as três classes de postura.

2.2.2 Parâmetros de Configuração e Treinamento

Para a detecção de poses com MediaPipe, foi utilizada a configuração com `model_complexity=1` e `static_image_mode=True`. O classificador RandomForest foi treinado com os seguintes hiperparâmetros principais: `n_estimators=200`, `class_weight='balanced'` (para mitigar o impacto de desbalanceamentos residuais após a extração de features) e `random_state=42`. As features extraídas foram normalizadas utilizando `StandardScaler` do Scikit-learn antes de serem fornecidas ao modelo.

2.2.3 Resultados e Métricas

A extração de features com MediaPipe foi bem-sucedida em 246 das 296 imagens de treino (aproximadamente 83%) e em 81 das 99 imagens de teste (aproximadamente 81.8%). Apenas estas amostras com poses detectadas foram utilizadas para o treinamento e avaliação do classificador RandomForest.

A acurácia geral do Modelo A no conjunto de teste foi de **62.96%**. O relatório de classificação detalhado para cada classe no conjunto de teste é apresentado na Tabela 1.

Tabela 1: Relatório de Classificação do Modelo A (MediaPipe + RandomForest) no Conjunto de Teste.

Classe	Precision	Recall	F1-score	Support
em_pe	0.742	0.767	0.754	30
movimento	0.519	0.538	0.528	26
sentado	0.609	0.560	0.583	25
Accuracy			0.630	81
Macro Avg	0.623	0.622	0.622	81
Weighted Avg	0.629	0.630	0.629	81

Fonte: model_A_mp_metrics.json

A matriz de confusão para o conjunto de teste (Tabela 2), com classes na ordem 'em_pe', 'movimento', 'sentado' (linhas representando os valores reais e colunas os valores preditos), foi:

Tabela 2: Matriz de Confusão do Modelo A (MediaPipe + RandomForest) no Conjunto de Teste.

		Predito		
		em_pe	movimento	sentado
Real	em_pe	23	7	0
	movimento	3	14	9
	sentado	5	6	14

Fonte: model_A_mp_metrics.json

Esta matriz mostra, por exemplo, que 23 instâncias de 'em pé' foram corretamente classificadas, enquanto 7 foram confundidas como 'movimento'. A classe 'movimento' foi frequentemente confundida com 'sentado' (9 instâncias).

2.3 Modelo B: YOLOv8-cls (Classificação)

2.3.1 Descrição da Abordagem

O Modelo B utilizou uma abordagem de aprendizado profundo (Deep Learning) para classificação de imagem inteira. Especificamente, foi realizado o fine-tuning de um modelo YOLOv8 Nano pré-treinado para classificação (`yolov8n-cls.pt`) nas classes de postura

definidas. Esta abordagem permite que o modelo aprenda a extrair características visuais relevantes diretamente dos pixels da imagem para realizar a distinção entre as posturas, beneficiando-se do conhecimento transferido dos grandes datasets em que foi pré-treinado.

2.3.2 Parâmetros de Configuração e Treinamento

O modelo base para fine-tuning foi o `yolov8n-cls.pt`. O treinamento foi configurado para um máximo de 50 épocas, mas utilizou um mecanismo de Early Stopping com paciência de 10 épocas, resultando na interrupção do treinamento na 14ª época, com o melhor modelo sendo identificado na 4ª época. As imagens de entrada foram redimensionadas para 128×128 pixels e processadas em batches de tamanho 16. O otimizador selecionado automaticamente pela biblioteca Ultralytics foi o AdamW (taxa de aprendizado inicial de 0.001429, momentum de 0.9). As curvas de treinamento e validação são apresentadas na Figura 1.

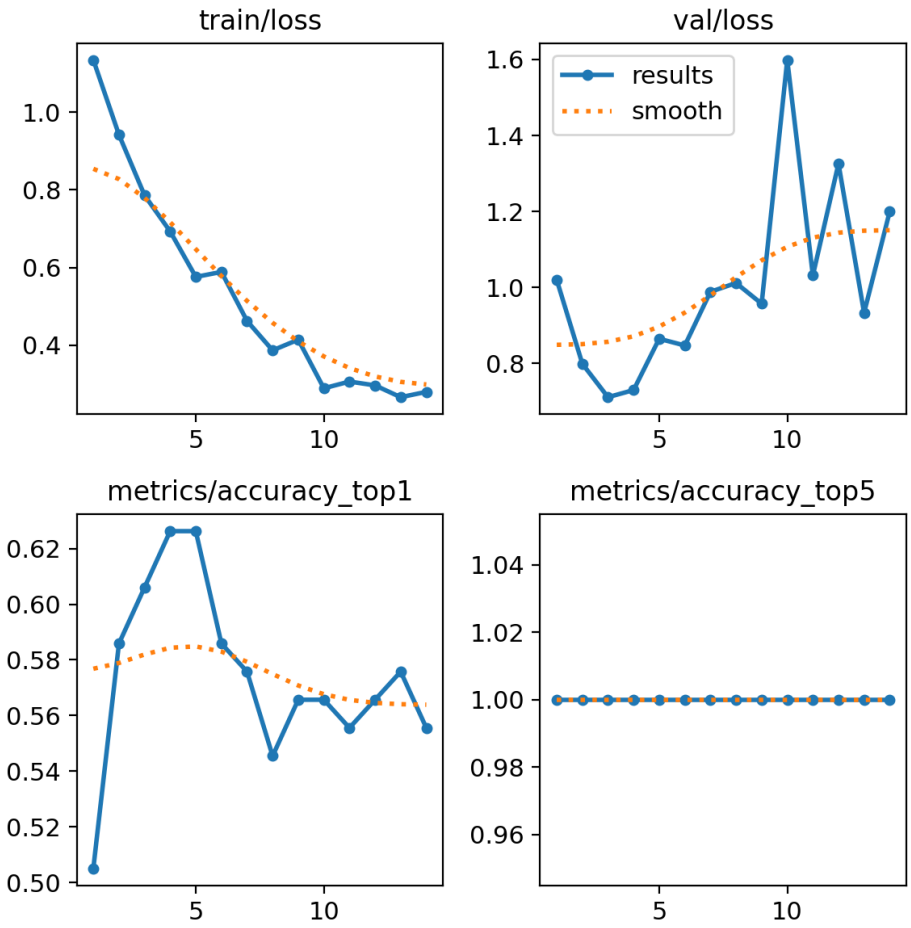

Figura 1: Curvas de treinamento e validação do Modelo B (YOLOv8-cls): loss de treino/validação (acima) e acurácia top-1/top-5 na validação (abaixo).

Fonte: results.png (Arquivo enviado)

2.3.3 Resultados e Métricas

O Modelo B (YOLOv8-cls) alcançou uma acurácia Top-1 de **62.63%** no conjunto de validação. A matriz de confusão para o conjunto de validação é mostrada na Figura 2 e

Figura 3, e os dados numéricos na Tabela 3.

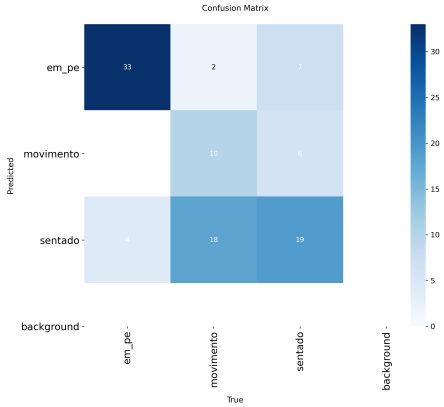

Figura 2: Matriz de Confusão (Valores Absolutos) do Modelo B (YOLOv8-cls) no Conjunto de Validação.

Fonte: confusion_matrix.png

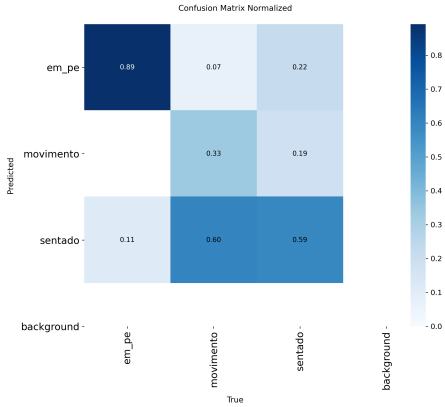

Figura 3: Matriz de Confusão Normalizada do Modelo B (YOLOv8-cls) no Conjunto de Validação.

Fonte: confusion_matrix_normalized.png

Tabela 3: Dados da Matriz de Confusão do Modelo B (YOLOv8-cls) no Conjunto de Validação.

		Predito		
		em_pe	movimento	sentado
Real	em_pe	33	2	7
	movimento	0	10	6
	sentado	4	18	19

Fonte: model_B_yolo_metrics.json e confusion_matrix.png

Com base na matriz de confusão acima (Tabela 3), foram calculadas as métricas de Precision, Recall e F1-score para cada classe (Tabela 4). A ordem das classes é 'em_pe', 'movimento', 'sentado'.

Tabela 4: Relatório de Classificação (calculado) do Modelo B (YOLOv8-cls) no Conjunto de Validação.

Classe	Precision	Recall	F1-score	Support (Val)
em_pe	0.892	0.786	0.835	42
movimento	0.333	0.625	0.435	16
sentado	0.594	0.463	0.520	41
Accuracy (Top-1)			0.626	99
Macro Avg	0.606	0.625	0.597	99
Weighted Avg	0.680	0.626	0.634	99

A classe 'sentado' foi frequentemente confundida como 'movimento' (18 instâncias), e a classe 'movimento' teve uma precisão baixa (0.333).

3 Análise Comparativa dos Modelos

Ambos os modelos apresentaram acurácias globais muito similares (Modelo A: 62.96%, Modelo B: 62.63%). A Tabela 5 compara os F1-scores por classe.

Tabela 5: Comparação de F1-scores por Classe entre Modelo A e Modelo B.

Classe	Modelo A (MediaPipe+RF) F1	Modelo B (YOLOv8-cls) F1
em_pe	0.754	0.835
movimento	0.528	0.435
sentado	0.583	0.520

O Modelo B (YOLO) demonstrou superioridade na classificação da classe 'em pé'. Contudo, o Modelo A (MediaPipe+RF) apresentou F1-scores ligeiramente melhores para as classes 'movimento' e 'sentado', que se mostraram mais desafiadoras para ambos os modelos. Uma limitação notável do Modelo A é sua dependência da detecção bem-sucedida da pose pelo MediaPipe, que falhou em aproximadamente 17-18% das imagens. O Modelo B (YOLO) processa todas as imagens de entrada. O treinamento do YOLO foi mais curto em termos de épocas devido ao early stopping, mas cada época de um modelo de deep learning pode ser computacionalmente mais intensiva. Ambos os modelos evidenciaram dificuldade em distinguir 'sentado' de 'movimento', sugerindo que estas classes, conforme definidas pelas regras geométricas da AT1 ou pela sua natureza intrínseca, são visualmente ambíguas ou o dataset de treino carece de variabilidade suficiente para uma distinção mais clara.

4 Seleção do Modelo para AT3

Considerando os resultados e as características de cada modelo, o **Modelo A (MediaPipe + RandomForest)** é selecionado para integração na AT3.

A justificativa para esta escolha se baseia nos seguintes pontos:

- Embora a acurácia global seja similar à do Modelo B, o Modelo A apresentou um desempenho ligeiramente mais robusto e equilibrado (F1-scores) para as classes 'movimento' e 'sentado', que são semanticamente importantes para um sistema de monitoramento de comportamento postural.

- A abordagem de extração de keypoints de pose (MediaPipe) é intrinsecamente alinhada com o problema de "Reconhecimento e Monitoramento de Posturas Humanas". As features geradas são interpretáveis e diretamente relacionadas à geometria do corpo humano, o que pode ser vantajoso para futuras análises ou refinamentos.

- A falha na detecção de pose pelo MediaPipe (resultando em não classificação para algumas amostras) pode ser explicitamente tratada na API da AT3, por exemplo, retornando um status 'postura não identificada' ou processando apenas frames onde a pose é confiavelmente detectada. Esta transparência pode ser preferível a uma classificação potencialmente incorreta com alta confiança por um modelo end-to-end em casos ambíguos.

- A inferência do RandomForest sobre features pré-extraídas é geralmente leve, embora a extração de features do MediaPipe adicione um custo computacional. Para uma PoC, este pipeline é viável e elucidativo.

5 Conclusão da AT2

A AT2 permitiu a exploração e avaliação de duas abordagens distintas para a classificação de posturas humanas. O Modelo A, baseado em MediaPipe e RandomForest, e o Modelo B, um classificador YOLOv8-cls fine-tuned, alcançaram performances globais comparáveis no dataset trabalhado. A análise detalhada por classe e as características intrínsecas de cada modelo, incluindo a interpretabilidade das features e a robustez nas classes mais desafiadoras, levaram à seleção do Modelo A para a próxima fase do projeto. Esta etapa ressaltou a importância da qualidade dos rótulos e da variabilidade do dataset, bem como os trade-offs entre diferentes paradigmas de modelagem.